

Raport zbiorczy: non-targeted lipidomics analysis

Analiza wykonana programistycznie w Pythonie. Dokument opisuje wyłącznie tor non-targeted. Analiza targeted została celowo pominięta zgodnie z poleceniem użytkownika; plik targeted data.xlsx nie został użyty do obliczeń, filtrowania ani interpretacji wyników.

1. Zakres i cel

Celem było przygotowanie odtwarzalnego workflow dla danych LC-MS z projektu lipidomiki mleka ludzkiego M1 vs M12. Analiza obejmuje audyt danych, filtrowanie blank/QC/obecności, ocenę RSD, preprocessing, PCA, eksplorację rozkładu cech oraz statystykę M1 vs M12 na poziomie dawczyni. Wyniki nie są identyfikacją lipidów, ponieważ tabela non-targeted zawiera cechy opisane przez RT, m/z i intensywności, bez potwierdzających adnotacji MS/MS.

2. Dane wejściowe i audyt

Użyto dwóch plików: nontargeted table 5 000 threshold.csv oraz metadata_M1_M12 2 05 2026.xlsx. Tabela non-targeted zawierała 752 wiersze cech oraz 55 kolumn typu [Vol], z których do analizy użyto 40 próbek biologicznych, 10 QC i 1 blank. Cztery kolumny D2 M12 wykluczono, ponieważ metadane i opis projektu wskazują, że dawczyni D2 została wykluczona z powodu braku próbek M1.

Element	Wartość / obserwacja
Cechy w tabeli wejściowej	752
Kolumny [Vol] łącznie	55
Próbki biologiczne użyte	40
QC użyte	10
Blank użyty	1
Wykluczone kolumny D2	4
Braki w komórkach próbek biologicznych	20039
Braki w komórkach QC	4973


W audycie wykryto niezgodności dokładnych nazw plików między metadanymi i nagłówkami feature table, głównie dla kilku próbek D3 oraz QC_day_8_6 / QC_day_8_9. Aby nie usuwać prawidłowych biologicznie próbek z powodu literówek w sufiksie pliku, próbki biologiczne połączono przez kanoniczny Sample_ID odtworzony z nagłówka kolumny, a nie przez ścisłe dopasowanie całej nazwy pliku. Problem został zapisany w processed_data/metadata_audit_summary.json.

3. Preprocessing i filtracja

Filtrowanie wykonano w kolejności zgodnej z logiką instrukcji: blank, obecność w QC, obecność w próbkach biologicznych, RSD w QC. Wartości puste i zerowe traktowano jako

brak detekcji. Kryterium blank: cecha została odrzucona, jeżeli średni sygnał w blanku był większy lub równy 10% średniego sygnału w próbkach biologicznych. Kryterium QC: do dalszej pracy wybrano wariant 70% QC, ponieważ wariant 100% był bardzo restrykcyjny. Kryterium próbek biologicznych: cecha musiała być obecna w co najmniej 70% próbek w przynajmniej jednym punkcie czasowym, aby nie usuwać potencjalnych cech specyficznych dla M1 albo M12.


Etap	Liczba cech
Raw feature table	752
After blank filter <10%	575
After blank + 100% QC presence	129
After blank + 70% QC presence	214
After blank + 100% Sample presence	69
After blank + 70% all Sample presence	152
After blank + 70% in at least one timepoint	204
Candidate: blank + 70% QC + 70% group	160
Final: candidate + QC RSD ≤30%	94
Strict accepted subset: QC RSD ≤20%	73



Rys. 1. Liczba cech po kolejnych etapach filtracji non-targeted.

Ocena RSD w QC

Po filtrach blank + 70% QC + 70% w grupie uzyskano 160 cech-kandydatów. Spośród nich 73 miały RSD ≤20%, 21 miały RSD 20–30% i zostały zatrzymane z flagą, a 66 miało RSD >30% i zostało usunięte. Finalna macierz obejmuje 94 cechy.




Rys. 2. Histogram stabilności analitycznej cech-kandydatów w próbkach QC.

4. Transformacja danych


Do analiz wielowymiarowych i statystycznych użyto finalnej macierzy cech. Po filtracji brakujące lub zerowe wartości imputowano połową minimalnej dodatniej wartości danej cechy. Następnie zastosowano transformację log2. PCA wykonano na macierzy log2 po autoskalowaniu cech, czyli po z-score liczonym dla każdej cechy. Ta kolejność jest zasadna, ponieważ log2 stabilizuje skalę intensywności i zmniejsza wpływ bardzo wysokich pików, a autoskalowanie nadaje porównywalną wagę cechom o różnych zakresach sygnału.

5. Analiza eksploracyjna i PCA

PCA wyjaśnia 49.1% wariancji przez PC1 i 19.8% przez PC2. QC tworzą zwartą grupę względem próbek biologicznych, co wspiera wykorzystanie finalnej macierzy do eksploracji. Jednocześnie rozkład próbek biologicznych wskazuje, że separacja M1/M12 nie jest jedynym źródłem zmienności; widoczny jest także wpływ dawczyni i replikatów.



Rys. 3. PCA próbek i QC po imputacji, log2 i autoskalowaniu cech.




Rys. 4. Mapa RT-m/z pokazująca, które cechy przeszły kolejne filtry.

6. Porównanie M1 vs M12

Aby uniknąć pseudoreplikacji, replikaty techniczne i ekstrakcyjne zredukowano przez średnią do poziomu dawczyny i punktu czasowego. Głównym testem był parowany test Wilcozona dla pięciu par dawczyń. Dodatkowo wyeksportowano test U Manna-Whitneya jako wariant zgodny z kartą ćwiczenia, ale nie traktowano go jako głównego testu projektowego, ponieważ design jest longitudinalny/parowany.


Po korekcji Benjamini-Hochberg nie uzyskano cech istotnych przy $FDR < 0,05$. Liczba cech FDR-istotnych: 0. Najniższe p-value w zestawie wyniosło 0,0625, a odpowiadające q-value 0,29375. Oznacza to, że można wskazać kandydatów do dalszej walidacji, ale nie wolno nazywać ich markerami biologicznymi bez identyfikacji i niezależnego potwierdzenia.



Rys. 5. Volcano plot M12 vs M1 na podstawie średniego $\log_2FC$ i parowanego testu Wilcoxona.

Feature	m/z	RT [min]	$\log_2FC$ M12-M1	p	q	QC RSD [%]
F0052	761.5980	10.69	-3.08	0.0625	0.2938	15.5
F0187	633.2142	0.98	-2.35	0.0625	0.2938	21.5
F0119	809.5963	10.06	-1.78	0.0625	0.2938	20.8
F0225	912.8182	34.54	-1.76	0.0625	0.2938	17.5
F0026	812.6817	13.15	-1.63	0.0625	0.2938	11.4
F0105	523.3660	2.34	-1.56	0.0625	0.2938	25.4
F0162	745.5656	11.24	-1.56	0.0625	0.2938	19.3
F0012	785.5977	10.04	-1.44	0.0625	0.2938	18.7
F0072	495.3345	1.91	-1.41	0.0625	0.2938	24.9
F0097	939.8296	30.08	-1.32	0.0625	0.2938	11.8

Tabela 1. Najwyżej rankingowane cechy-kandydaci. Nie są to zidentyfikowane lipidy ani potwierdzone markery.



Rys. 6. Heatmapa top cech po agregacji do poziomu dawczyni.

7. Ograniczenia interpretacyjne

Najważniejsze ograniczenie: cechy non-targeted nie mają pewnych nazw lipidów. Ich interpretacja biologiczna wymaga adnotacji MS/MS, kontroli adduktów/izotopów oraz walidacji standardami lub bazami widm. Drugie ograniczenie to jeden blank dostępny tylko dla day9, co nie pozwala w pełni kontrolować tła każdego dnia pomiarowego. Trzecie ograniczenie to mała liczba niezależnych jednostek biologicznych: $n = 5$ par dawczyń. Przy takim n brak FDR-istotnych cech jest metodologicznie wiarygodnym wynikiem, a nie porażką analizy.

Nie wykonano PLS-DA jako głównego narzędzia marker-selection, ponieważ przy $n = 5$ par i bez niezależnej walidacji ryzyko overfittingu byłoby wysokie. W raporcie skupiono się na PCA, QC i ostrożnej statystyce donor-level.

8. Pliki wynikowe i odtwarzalność

Cała analiza znajduje się w `analysis_non_targeted.py`. Skrypt można uruchomić poleceniem: **`python analysis_non_targeted.py --input-dir input_data --output-dir ..`**. Wyniki liczbowe zapisano w `processed_data/`, a wykresy w `figures/`. Notebook `analysis_non_targeted.ipynb` jest wrapperem uruchamiającym ten sam skrypt.

Plik/folder	Zawartość
figures/	wykresy PNG użyte w plakacie i raporcie
processed_data/filtering_summary.csv	liczby cech po kolejnych filtrach
processed_data/final_matrix_raw_volumes.csv	finalna macierz wolumenów
processed_data/final_matrix_log2_imputed.csv	macierz po imputacji i log2
processed_data/pca_scores.csv	wyniki PCA dla obiektów
processed_data/univariate_statistics_m1_vs_m12.csv	statystyka M1 vs M12
processed_data/results_summary.json	podsumowanie automatyczne dla raportu/plakatu

9. Materiały źródłowe z ZIP

Instrukcje projektowe: ćwiczenie4_dane_metadane.docx, ćwiczenie6_preprocessing_QC.docx, ćwiczenie7_Przygotowanie macierzy zmiennych.docx oraz ćwiczenie X_Statystyka i analiza danych.docx. Materiały pomocnicze: WykładTM.pdf, wykłady cd.pdf, wykład 1 upd.pdf oraz publikacje w folderze Publikacje naukowe, m.in. Heuckeroth et al. 2024 Nat Protoc i Schmid et al. 2021 Nat Commun.